


Szenario

Stellen Sie sich vor: Sie arbeiten in einem Unternehmen, das täglich Millionen von Bildern verarbeitet - sei es für die medizinische Bildanalyse, für soziale Netzwerke oder für die Filmindustrie.

Eines Tages stoßen Sie auf ein Problem: Einige der Bilder sind beschädigt oder unvollständig, und Sie benötigen eine schnelle und effiziente Möglichkeit, sie zu reparieren oder sogar neue, realistische Bilder zu erstellen.

Genau das ermöglichen Autoencoder (AE) und Variational Autoencoder (VAE).



Quelle: <https://stackabuse.com/autoencoders-for-image-reconstruction-in-python-and-keras/>

Anwendungsbereiche

1. Datenkompression:

- Reduzierung der Datenmenge, ohne wichtige Informationen zu verlieren.
- Beispiel: Bildkompression.

2. Rauschunterdrückung:

- Entfernen von Rauschen aus den Daten.
- Beispiel: Verbesserung der Bildqualität.


3. Anomaly Detection:

- Erkennen von Anomalien oder Ausreißern in den Daten.
- Beispiel: Erkennung von Betrugstransaktionen.


4. Feature-Learning:

- Features aus Daten automatisch zu extrahieren.
- Beispiel: Datenaufbereitung für Bilderkennung oder im NLP

original



reconstructed



original + noise



reconstructed




Was ist ein Autoencoder (AE)?

Ein Autoencoder ist ein spezieller Typ eines neuronalen Netzwerks, das darauf trainiert wird, Features so zu extrahieren, dass die ursprüngliche Eingabe mit minimalen Verlusten rekonstruiert werden kann.

Ziel:

Eine effiziente Komprimierung der Daten.




Grundprinzip

Ein Autoencoder besteht aus zwei Hauptkomponenten: einem **Encoder**, der die Eingabedaten in eine komprimierte, niedrigdimensionale Darstellung umwandelt, latenter Raum genannt, und einem **Decoder**, der versucht, die Originaldaten aus dieser komprimierten Darstellung wiederherzustellen.

Durch diesen Prozess lernt das Netzwerk, relevante Merkmale der Daten zu erkennen, die für eine genaue Rekonstruktion erforderlich sind. Das Ziel ist es, die wesentlichen Informationen der Daten zu extrahieren, ohne unnötige Details zu speichern.

$$z = f(x) \quad \text{und} \quad \hat{x} = g(z)$$



Funktionsweise: Encoder

Der Encoder transformiert hochdimensionale Eingabedaten (z.B. Bilder, Zeitreihen, Texte) in eine niedrigdimensionale Repräsentation, die als **latenter Raum** bezeichnet wird.

Architektur: Der Encoder besteht in der Regel aus mehreren Schichten von Neuronen, die zunehmend abstraktere Merkmale der Eingabedaten extrahieren. Oft werden dabei **nicht-lineare Aktivierungsfunktionen** (wie ReLU oder Sigmoid) verwendet, um komplexe Beziehungen in den Daten zu modellieren.


Ziel: Es geht nicht nur um eine reine Reduktion der Dimensionen, sondern um das Lernen relevanter Merkmale, die zur Rekonstruktion der Daten notwendig sind.

$$z = f(x) = \sigma(W_e x + b_e)$$

W_e – Gewichtsmatrix des Encoders

b_e – Bias

σ – Aktivierungsfunktion





Funktionsweise: Latenter Raum

Dieser Layer im Encoder-Netz repräsentiert eine stark komprimierte Version der Eingangsdaten und enthält die wesentlichen Merkmale, die der Decoder für die Rekonstruktion der ursprünglichen Daten benötigt.

Dimension:

Eine zu geringe Dimension führt zu einem Informationsverlust und schlechter Rekonstruktion.

Eine zu hohe Dimension zu einer Überanpassung führen kann, sodass keine sinnvolle Generalisierung stattfindet.



Funktionsweise: Decoder

Der Decoder nimmt die komprimierte Repräsentation aus dem latenten Raum und versucht, die ursprünglichen Daten mit minimalem Informationsverlust zu rekonstruieren.


Architektur: Decoder besteht ebenfalls aus mehreren Schichten. Dabei werden oft ähnliche Schichtstrukturen wie beim Encoder verwendet, aber in umgekehrter Reihenfolge (z.B. Transponierte Faltungsoperationen bei Bildern).

$$\hat{x} = g(z) = \sigma(W_d z + b_d)$$

W_d – Gewichtsmatrix des Decoders
 b_d – Bias
 σ – Aktivierungsfunktion

Ziel: Der Decoder maximiert die Übereinstimmung zwischen der rekonstruierten Ausgabe und der ursprünglichen Eingabe, häufig unter Verwendung einer geeigneten Verlustfunktion wie dem **Mean Squared Error (MSE)** oder **Cross-Entropy Loss** (geeignet bei Schwarz-Weiß-Bildern).

$$L(x, \hat{x}) = MSE(x, \hat{x}) = |x - \hat{x}|^2$$



Denoising (Entauschung)


Ziel: Der Denoising Autoencoder (DAE) wird trainiert, verrauschte Eingangsdaten (z.B. *Bilder mit zufälligem Rauschen oder beschädigte Daten*) in ihre rauschfreie Form zu rekonstruieren. Dabei lernt Autoencoder die relevanten Merkmale der Daten zu extrahieren, während er das Rauschen ignoriert.

Eingabemodifikation: Rauschen wird gezielt zu den Eingabedaten hinzugefügt.

Typische Arten von Rauschen sind Gaussian Noise oder Salt-and-Pepper Noise.

Latenter Raum: enthält eine rauschfreie, abstrahierte Darstellung der Eingabedaten.

Verlustfunktion: die Differenz zwischen den rekonstruierten sauberen Daten und den ursprünglichen sauberen Daten wird minimiert, nicht zwischen den verrauschten Eingaben und der Ausgabe.



QUIZ

1. Was ist das Hauptziel eines Autoencoders?

- A) Klassifikation von Daten
- B) Reduktion der Dimensionalität und Rekonstruktion der Eingabedaten
- C) Vorhersage zukünftiger Datenpunkte
- D) Datenverschlüsselung

2. Welche Komponenten hat ein Autoencoder?

- A) Encoder und Decoder
- B) Vorwärts- und Rückwärtspropagation
- C) Klassifikator und Regulator
- D) Normalisierer und Optimierer

3. Welche Art von Verlustfunktion wird typischerweise bei Autoencodern verwendet?

- A) Kreuzentropie-Verlust
- B) Mean Squared Error (MSE)
- C) Hinge-Verlust
- D) Logarithmischer Verlust

4. Welches der folgenden Probleme kann durch die Verwendung von Autoencodern gelöst werden?

- A) Bilderkennung
- B) Anomalieerkennung
- C) Textklassifikation
- D) Sequenzvorhersage

QUIZ

1. Was ist das Hauptziel eines Autoencoders?

- A) Klassifikation von Daten
- B) Reduktion der Dimensionalität und Rekonstruktion der Eingabedaten
- C) Vorhersage zukünftiger Datenpunkte
- D) Datenverschlüsselung

Antwort: B

2. Welche Komponenten hat ein Autoencoder?

- A) Encoder und Decoder
- B) Vorwärts- und Rückwärtspropagation
- C) Klassifikator und Regulator
- D) Normalisierer und Optimierer

Antwort: A

3. Welche Art von Verlustfunktion wird typischerweise bei Autoencodern verwendet?

- A) Kreuzentropie-Verlust
- B) Mean Squared Error (MSE)
- C) Hinge-Verlust
- D) Logarithmischer Verlust

Antwort: B

4. Welches der folgenden Probleme kann durch die Verwendung von Autoencodern gelöst werden?


- A) Bilderkennung
- B) Textklassifikation
- C) Anomalieerkennung
- D) Sequenzvorhersage

Antwort: C


Übungen

Rekonstruktion


Input Image



Generiertes Image



Rauschentfernung (Denoising)



NN_CNN_autoencoder_denoising.ipynb

3_Autoencoder_Tensorflow_MNIST_14x14.ipynb

Und / Oder

NN_autoencoder_MNIST.ipynb

TensorFlow-Tutorial (auf Google Colab oder local)

<https://www.tensorflow.org/tutorials/generative/autoencoder>