

Grenzen des Autoencoder (AE)


- **Fehlende generative Fähigkeiten / deterministischer Ansatz**
AE kann nur bedingt neuen Daten außerhalb von Trainingsdaten generieren.
- **Unstrukturierter latenter Raum**
Latenter Raum ist diskontinuierlich – kleine Änderungen im latenten Raum führen nicht unbedingt zu sinnvollen Änderungen bei der Rekonstruktion.
- **Anfälligkeit für Overfitting**
AE lernt direkt die Trainingsdaten.

Variational Autoencoder (VAE)

Der Autoencoder soll die Eingabedaten effizient zu komprimieren und zu rekonstruieren. VAE erweitert dieses Konzept durch die Einführung eines probabilistisch strukturierten latenten Raums.

Dies ermöglicht nicht nur eine bessere Datenrekonstruktion, sondern auch die Generierung neuer Daten und ein besseres Verständnis der Datenverteilung.

- **Probabilistischer Ansatz**
- **Variationsinferenz**
- **Erkennungsmodell**
- **ELBO (Evidence Lower Bound)**
- **Reparametrisierungstrick**




<https://www.youtube.com/watch?v=sV2FOdGqIX0>

Warum „probabilistisch“?

Exkurs: probabilistisch (adj.) - die Wahrscheinlichkeit berücksichtigend

Ein VAE modelliert den latenten Raum als eine **Wahrscheinlichkeitsverteilung** möglicher Zustände und nicht als einen festen Satz von Vektoren. Diese Verteilung wird durch eine Funktion beschrieben.




Was kann VAE dadurch?

Unsicherheit modellieren: Erfassen, dass es mehrere plausible latente Repräsentationen für eine gegebene Eingabe geben kann.

Variabilität generieren: Neue Daten erzeugen, die Variationen der Trainingsdaten darstellen.

Struktur im latenten Raum schaffen: Einen kontinuierlichen und geordneten latenten Raum ermöglichen, in dem ähnliche Eingaben zu ähnlichen Verteilungen führen.

2-dimensionaler latenter Raum



Variationsinferenz

In einem VAE möchten wir die posteriore Verteilung $p(z|x)$ berechnen, wobei z die latente Variable und x die beobachteten Daten sind.

Es handelt sich um eine Approximation der tatsächlichen posterioren Verteilung $p(z|x)$, da diese Berechnung in der Regel schwierig oder unmöglich ist.

Nach Satz von Bayes: $p(z|x) = \frac{p(x|z)p(z)}{p(x)}$ Problem: $p(x) = \int p(x|z)p(z)dz$
diese Integration ist unlösbar (intractable)

Lösung: Man führt $q(z|x)$ ein, die $p(z|x)$ approximiert.

Erkennungsmodell (recognition model)

Das praktische Werkzeug zur Durchführung der Variationsinferenz.

Das **Erkennungsmodell** beschreibt den Teil des Modells, der die latente Variable z aus den beobachteten Daten x herleitet (inferiert).

In einem VAE ist das Erkennungsmodell der **Encoder**, der $q(z|x)$ lernt.

$$q(z|x) = \text{Encoder}(x)$$

Ziel: $q(z|x)$ so nah wie möglich an $p(z|x)$ zu bringen.

Loss Funktion: ELBO (Evidence Lower Bound)

$$ELBO = \underbrace{-D_{KL}(q(z|x)||p(z))}_{\text{KL-Divergenz}} + \underbrace{E_{q(z|x)}[\log p(x|z)||p(z)]}_{\text{Rekonstruktionsverlust}}$$

Die Kullback-Leibler-Divergenz (**KL-Divergenz**) ist ein Maß für die Güte der Approximation.

Dieser Term reguliert die Verteilung der latenten Variablen z und sorgt dafür, dass die approximierte posteriore Verteilung $q(z|x)$ nicht zu stark von der priori-Verteilung $p(z)$ abweicht.

Der **Rekonstruktionsverlust** beschreibt den Erwartungswert der Log-Wahrscheinlichkeit, dass die Eingabedaten x rekonstruiert werden, gegeben die latenten Variablen z , die aus der Verteilung $q(z|x)$ gezogen werden.


$$\textit{Evidence} \hat{=} \log(p(x))$$

Lossfunktion: „latent loss“ oder KL-Divergenz

Zweck: Die KL-Divergenz zu minimieren, um eine möglichst gute Approximation zu erhalten.

Spezifische Form für Normalverteilungen:

$$D_{KL}(q(z|x)||p(z)) = \frac{1}{2} \sum_{i=1}^d (\mu_i^2 + \sigma_i^2 - \log(\sigma_i^2) - 1)$$



- μ_i und σ_i sind die Mittelwerte und Standardabweichungen der Verteilungen der latenten Variablen, die durch den Encoder gelernt wurden.
- Die Summe läuft über die Dimensionen des latenten Raums d .

<https://englishprobabilistic-machine-learninglbo-interactive--or5u7m.streamlit.app/>

Lossfunktion: Rekonstruktionsverlust


In der Praxis werden dafür eingesetzt:

- Binäre Kreuzentropie (BCE)
- Mittlere quadratische Fehler (MSE)



Siehe Autoencoder

Training: Prozess in Schritten



Reparametrisierungstrick

Dies ist eine technische Lösung, um differentielles Sampling aus $q(z|x)$ zu ermöglichen. Dadurch kann die ELBO mit Gradientenabstieg maximiert werden.

Anstatt direkt $z \sim N(\mu, \sigma^2)$ zu sampeln, wird z durch eine Transformation berechnet:

$$z = \mu(x) + \sigma(x) \cdot \epsilon$$


deterministisch, von Eingabedaten und Modellparametern abhängig

zufällig

wobei $\epsilon \sim N(0, 1)$ eine Zufallsvariable ist, die aus einer Standardnormalverteilung ($\mu = 0, \sigma = 1$) gezogen wird.

Latenter Raum wird „per Design“ kontinuierlich.

Reparametrisierungstrick



QUIZ

1. Was ist der Hauptunterschied zwischen einem Autoencoder (AE) und einem Variational Autoencoder (VAE)?

- A) AEs verwenden keine Aktivierungsfunktionen, VAEs schon.
- B) AEs sind deterministisch, VAEs modellieren Wahrscheinlichkeitsverteilungen.
- C) AEs sind für Bilddaten, VAEs für Textdaten.
- D) AEs haben einen Encoder, VAEs nicht.

2. Welche zusätzliche Komponente wird bei VAEs eingeführt, die bei normalen AEs nicht vorhanden ist?

- A) Ein zusätzlicher Decoder
- B) Ein zusätzlicher Optimierer
- C) Ein zusätzlicher Klassifikator
- D) Eine latente Variable, die als Wahrscheinlichkeitsverteilung modelliert wird

3. Welche Verlustfunktion wird typischerweise bei VAEs verwendet?

- A) Mean Squared Error (MSE)
- B) Kreuzentropie-Verlust
- C) Die Summe aus Rekonstruktionsverlust und KL-Divergenz
- D) Hinge-Verlust

4. Was beschreibt die KL-Divergenz in einem VAE?

- A) Die Abweichung zwischen der rekonstruierten und der ursprünglichen Eingabe
- B) Die Abweichung zwischen der approximierten latenten Verteilung und der gewünschten Verteilung
- C) Die Genauigkeit der Klassifikation
- D) Die Differenz zwischen Trainings- und Validierungsverlust

QUIZ

1. Was ist der Hauptunterschied zwischen einem Autoencoder (AE) und einem Variational Autoencoder (VAE)?

- A) AEs verwenden keine Aktivierungsfunktionen, VAEs schon.
- B) AEs sind deterministisch, VAEs modellieren Wahrscheinlichkeitsverteilungen.
- C) AEs sind für Bilddaten, VAEs für Textdaten.
- D) AEs haben einen Encoder, VAEs nicht.

Antwort: B

2. Welche zusätzliche Komponente wird bei VAEs eingeführt, die bei normalen AEs nicht vorhanden ist?

- A) Ein zusätzlicher Decoder
- B) Ein zusätzlicher Optimierer
- C) Ein zusätzlicher Klassifikator
- D) Eine latente Variable, die als Wahrscheinlichkeitsverteilung modelliert wird

Antwort: D

3. Welche Verlustfunktion wird typischerweise bei VAEs verwendet?

- A) Mean Squared Error (MSE)
- B) Kreuzentropie-Verlust
- C) Die Summe aus Rekonstruktionsverlust und KL-Divergenz
- D) Hinge-Verlust

Antwort: C


4. Was beschreibt die KL-Divergenz in einem VAE?

- A) Die Abweichung zwischen der rekonstruierten und der ursprünglichen Eingabe
- B) Die Abweichung zwischen der approximierten latenten Verteilung und der gewünschten Verteilung
- C) Die Genauigkeit der Klassifikation
- D) Die Differenz zwischen Trainings- und Validierungsverlust

Antwort: B

Übungen

MNIST
(CPU)



Anime-Gesichter (GPU)

