

Orange Data Mining

Eine praktische Einführung mit vollständiger ML-Pipeline

Zielgruppe: Lehrkräfte mit informatischer Vorerfahrung
Software: Orange Data Mining 3.40 | Datensatz: Titanic (Kaggle)

1 Was ist Orange?

Orange ist eine Open-Source-Software für Datenanalyse und maschinelles Lernen. Entwickelt ab 1996 an der Universität Ljubljana (Slowenien) von der Forschungsgruppe Bioinformatics Laboratory (Biolab) unter Leitung von Prof. Blaž Zupan, wird Orange heute von einem internationalen Team gepflegt und zählt zu den verbreitetsten visuellen ML-Werkzeugen im Bildungsbereich.

Das Leitprinzip von Orange lautet: Maschinelles Lernen soll ohne Programmierkenntnisse zugänglich sein. Statt Code werden grafische Bausteine – sogenannte Widgets – auf einer Arbeitsfläche (Canvas) zu einer Datenfluss-Pipeline zusammengestellt.

Kernmerkmale

- Kostenlos und quelloffen (MIT-Lizenz), verfügbar für Windows, macOS und Linux
- Über 100 Widgets für alle Schritte des ML-Prozesses: Laden, Erkunden, Vorverarbeiten, Trainieren, Auswerten
- Erweiterbar durch Add-ons: Text Mining, Bioinformatik, Time Series, Image Analytics
- Ohne Python-Kenntnisse einsetzbar – und gleichzeitig als Python-Bibliothek nutzbar

Hinweis: Orange herunterladen

Aktuelle Version 3.40 kostenlos verfügbar unter:

<https://orangedatamining.com/download/>

Unterstützte Betriebssysteme: Windows 10/11, macOS 11+, Ubuntu 20.04+

Einsatzbereiche


Orange eignet sich für schulischen und universitären Unterricht ebenso wie für explorative Datenanalyse in der Forschung. Die visuelle Pipeline macht jeden Arbeitsschritt transparent und diskutierbar – ideal, um ML-Konzepte zu erschließen, ohne sich im Code zu verlieren.

2 Die Orange-Oberfläche

Beim Start von Orange öffnet sich der Canvas – eine leere Arbeitsfläche. Alle Werkzeuge befinden sich in der Widget-Leiste am linken Rand.

2.1 Der Canvas

Der Canvas ist der zentrale Arbeitsbereich. Widgets werden hier platziert und durch Verbindungslinien zu einer Pipeline verknüpft. Daten fließen stets von links nach rechts. Die gesamte Pipeline kann als .ows-Datei gespeichert und weitergegeben werden.



2.2 Die Widget-Leiste

Die Widget-Leiste ist in thematische Gruppen unterteilt:

- **Data:** Daten laden, transformieren und speichern
- **Visualize:** Diagramme, Verteilungen, Streudiagramme
- **Model:** Algorithmen wie Tree, kNN, Logistic Regression
- **Evaluate:** Test and Score, Confusion Matrix, ROC
- **Unsupervised:** k-Means, PCA, t-SNE

Widgets lassen sich per Doppelklick auf die Leiste, per Drag & Drop auf den Canvas oder über die Suchfunktion (Strg+F / Cmd+F) hinzufügen.

2.3 Widgets verbinden

Um zwei Widgets zu verbinden, wird mit der Maus vom Ausgabepunkt des ersten Widgets (kleiner Kreis rechts) zum Eingabepunkt des zweiten gezogen. Ein Dialogfeld ermöglicht die Auswahl der Verbindungsart – die sinnvollste Verbindung ist meist bereits vorausgewählt.

Der Datenfluss ist gerichtet und reaktiv: Sobald ein Widget neue Daten erhält, verarbeitet es diese sofort und gibt das Ergebnis automatisch an nachfolgende Widgets weiter.

2.4 Daten einsehen

Ein Doppelklick auf ein Widget öffnet dessen Einstellungs- und Anzeigefenster. So lässt sich an jeder Stelle der Pipeline überprüfen, welche Daten aktuell vorliegen. Der kleine Pfeil am Ausgabepunkt eines Widgets ruft zusätzlich eine Schnellvorschau auf.

3 Die Pipeline: Wer überlebt die Titanic?

In diesem Abschnitt bauen wir gemeinsam eine vollständige ML-Pipeline auf. Ausgehend vom Titanic-Datensatz durchlaufen wir alle typischen Stationen: Laden, Erkunden, Vorverarbeitung, Training und Auswertung.

Widget-Info: Datensatz: Titanic

- Quelle: Kaggle (train.csv) – liegt dem Dokument als Datei bei
- Umfang: 891 Passagiere, 12 Merkmale
- Zielgröße: Survived (0 = nicht überlebt, 1 = überlebt)
- Fragestellung: Lassen sich Überlebensentscheidungen aus demographischen und Buchungsmerkmalen vorhersagen?

Übersicht der Pipeline: File → Data Table → Distributions / Scatter Plot → Select Columns → Preprocess → Tree / Logistic Regression → Test and Score → Confusion Matrix / ROC / Tree Viewer

Station 1: Daten laden

In der ersten Station laden wir den Titanic-Datensatz in Orange und prüfen die automatisch erkannten Spaltentypen.

Hands-on

1. Orange starten – der Canvas ist leer.
2. In der Widget-Leiste auf Data klicken, dann File doppelklicken (oder Strg+F → 'File').
3. Im File-Widget auf das Ordnersymbol klicken und 'Kaggle_Titanic_train.csv' öffnen.
4. Orange erkennt die Spaltentypen automatisch. Statuszeile: 891 instances, 12 features.
5. Prüfe: Survived sollte als Target markiert sein. Falls nicht: Spaltenkopf anklicken → Target auswählen.

Widget-Info: File

Lädt tabellarische Daten aus lokalen Dateien. Unterstützte Formate: CSV, Excel (.xlsx), Tab-getrennte Dateien (.tab).

Spaltenzuordnungen:

- Feature: Reguläres Eingabemerkmale für das Training
- Target: Zielvariable – hier: Survived (genau eine Spalte)
- Meta: Begleitinformation ohne Trainingseinfluss (bleibt sichtbar)
- Skip: Spalte wird vollständig ignoriert

Station 2: Explorative Datenanalyse (EDA)

Bevor ein Modell trainiert wird, erkunden wir den Datensatz: Verteilungen, Muster und Auffälligkeiten.

2a Data Table

Hands-on

1. Data → Data Table auf den Canvas ziehen und mit File verbinden.
2. Data Table per Doppelklick öffnen: Alle 891 Zeilen sind sichtbar.
3. Beobachte: Age, Cabin und Embarked enthalten fehlende Werte (graue Zellen). Name, Ticket und PassengerId erscheinen für ML wenig informativ.

Widget-Info: Data Table

Zeigt den aktuellen Datensatz als interaktive Tabelle. Spalten können sortiert und gefiltert werden. Ausgewählte Zeilen werden als Teilmenge an verbundene Widgets weitergegeben.

- Fehlende Werte erscheinen als graue Zellen (oder 'NaN')
- Statuszeile oben links: Anzahl Instanzen und Merkmale auf einen Blick

2b Distributions

Hands-on

1. Visualize → Distributions auf den Canvas ziehen und mit File verbinden.
2. Im Dropdown oben verschiedene Merkmale wählen: Survived, Pclass, Age, Sex.
3. 'Group by' ist automatisch aktiviert → Survived: Balken werden nach Überlebensstatus eingefärbt.
4. Beobachte: Frauen überleben deutlich häufiger; Passagiere der 1. Klasse häufiger als die der 3. Klasse.

Widget-Info: Distributions

Zeigt die Häufigkeitsverteilung eines Merkmals als Balken- oder Histogrammdiagramm. Kategorische Merkmale → Balkendiagramm; numerische → Histogramm.

- Group by Target: Balken nach Zielvariable einfärben – erkennt Klassentrennbarkeit sofort
- Show relative frequencies: Zeigt prozentuale Anteile statt absolute Häufigkeiten
- Number of bins (bei numerischen Merkmalen): Granularität des Histogramms einstellen

2c Scatter Plot


Hands-on

1. Visualize → Scatter Plot auf den Canvas ziehen und mit File verbinden.
2. X-Achse: Age, Y-Achse: Fare, Color: Survived (blau = nicht überlebt, orange = überlebt).
3. Beobachte: Passagiere mit hohem Fahrpreis zeigen eine höhere Überlebensrate.
4. Wechsle zu: X = Pclass, Y = Age, Color = Survived, Shape = Sex – mehrere Dimensionen gleichzeitig sichtbar.

Widget-Info: Scatter Plot

Stellt den Datensatz zweidimensional dar. Farbe, Form und Größe der Punkte können mit weiteren Merkmalen kodiert werden.

- Jitter: Streut identische Punkte leicht auf – verhindert optische Überlappung bei diskreten Werten
- Find Informative Projections: Orange sucht automatisch die trennschärfste Achsenkombination
- Selektion: Ausgewählte Punkte werden als Teilmenge an nachfolgende Widgets weitergegeben



Station 3: Preprocessing

Rohdaten sind selten direkt trainierbereit. In dieser Station entfernen wir uninformative Merkmale und behandeln fehlende Werte.

3a Irrelevante Merkmale entfernen (Select Columns)

Folgende Spalten entfernen wir, da sie für die Vorhersage wenig Information tragen oder Probleme verursachen würden:

Spalte	Begründung
PassengerId	Laufende Nummer – kein inhaltlicher Zusammenhang mit Überleben
Name	Text-Freifeld – ohne Feature Engineering nicht verwertbar
Ticket	Freie Ticketnummer – kein systematischer Zusammenhang erkennbar
Cabin	Über 75 % fehlende Werte – zu lückenhaft für zuverlässiges Training

Hands-on

1. Data → Select Columns auf den Canvas ziehen und mit File verbinden.
2. Select Columns öffnen: Links erscheint die vollständige Merkmalliste.
3. PassengerId, Name, Ticket und Cabin per Drag & Drop in die linke Spalte 'Ignored' verschieben.
4. Survived bleibt als Target (blau, ganz oben). Die verbleibenden Merkmale bleiben als Features (grün).
5. Statuszeile: 891 instances, 8 features.

Widget-Info: Select Columns

Ermöglicht die manuelle Auswahl von Merkmalen durch Zuordnung in vier Kategorien.

- Features (grün): Eingangsmerkmale für das Modell
- Target (blau): Die vorherzusagende Variable – genau eine Spalte
- Meta (gelb): Begleitinformation, kein Einfluss auf Training
- Ignored (grau): Aus dem Datenstrom entfernt – Quelldatei bleibt unberührt

3b Fehlende Werte behandeln (Impute)

Nach dem Entfernen von Cabin verbleiben fehlende Werte in Age (ca. 19 %) und Embarked (2 Einträge). Das Impute-Widget füllt diese automatisch auf.


Hands-on

1. Data → Impute auf den Canvas ziehen und zum Eingang von Select Columns verbinden.
2. Impute öffnen. Die Strategie 'Average' / 'Most frequent value' wählen.
4. Statuszeile: 0 missing values.


Widget-Info: Impute

Ersetzt fehlende Werte durch berechnete Schätzwerte. Die Strategie kann global oder pro Merkmal eingestellt werden.

- Average / Most frequent: Schnell und robust – gut bei moderatem Anteil fehlender Werte
- Model-based: Verwendet ein internes Modell (z. B. kNN) zur Schätzung – aufwändiger, aber oft genauer
- Remove instances: Löscht Zeilen mit fehlenden Werten – nur bei sehr wenigen Fällen empfehlenswert
- Default value: Setzt einen manuell definierten Wert (z. B. 0 oder 'Unbekannt')

**Hands-on**

Achtung! Das Befüllen der Lücken mit der Strategie 'Average' / 'Most frequent value' führt zur Verzerrung des Datensatzes. Die Accuracy wird besser, aber die Ergebnisse sind nicht plausibel. Alternative:

Vergleich: Vor und nach dem Auffüllen der Lücken mit dem häufigsten Wert

Station 4: Training und Modellvergleich

Jetzt trainieren wir zwei Modelle und vergleichen ihre Leistung objektiv mit Test and Score.

4a Modelle konfigurieren und Pipeline schließen

Hands-on

1. Model → Tree auf den Canvas ziehen (als Input ,Select Cloumns' einstellen).
2. Model → Logistic Regression auf den Canvas ziehen.
3. Evaluate → Test and Score auf den Canvas ziehen.
4. ,Select Columns'-Ausgang mit Test and Score verbinden (oberer Eingang: Data).
5. Tree mit Test and Score verbinden (Eingang: Learner).
6. Logistic Regression ebenfalls mit Test and Score verbinden (zweiter Learner).
7. Test and Score öffnen → Sampling → Cross Validation → 10 Folds → Evaluate.

Widget-Info: Tree (Entscheidungsbaum)

Klassifiziert durch schrittweise Wenn-Dann-Regeln, die aus den Trainingsdaten gelernt werden. Sehr gut interpretierbar: Jede Entscheidung lässt sich nachvollziehen.

- Max depth: Maximale Tiefe des Baums – tiefere Bäume passen sich stärker an Trainingsdaten an (Overfitting-Risiko)
- Min samples in leaves: Mindestanzahl Datenpunkte pro Blattknoten – begrenzt Überanpassung
- Kriterium: Gini-Unreinheit oder Information Gain als Qualitätsmaß für Splits

Widget-Info: Logistic Regression

Trotz des Namens ein Klassifikationsverfahren. Schätzt die Wahrscheinlichkeit der Klassenzugehörigkeit und entscheidet anhand eines Schwellwerts (Standard: 0,5).

- C (Regularisierung): Kleines C = stärkere Regularisierung = einfacheres, robusteres Modell
- Solver: Optimierungsalgorithmus; 'Ridge' ist ein guter Standardwert
- Liefert kalibrierte Wahrscheinlichkeiten – besonders nützlich für die ROC-Analyse

Widget-Info: Test and Score

Bewertet ein oder mehrere Modelle auf denselben Daten mit derselben Methode – vergleichbar und fair.

- Cross Validation (k-Fold): Daten werden in k Teile geteilt; jeder Teil dient einmal als Testmenge – stabiles Verfahren
- AUC: Area under the ROC Curve – 1,0 = perfekt, 0,5 = zufällig
- CA (Classification Accuracy): Anteil korrekt klassifizierter Instanzen
- F1: Harmonisches Mittel aus Precision und Recall – robust bei ungleichen Klassengrößen

Nach dem Training zeigt Test and Score eine Vergleichstabelle. Typische Ergebnisse für diesen Datensatz:

Modell	AUC	CA	F1	Precision	Recall
Decision Tree	ca. 0,74	ca. 0,77	ca. 0,75	ca. 0,74	ca. 0,76
Logistic Regression	ca. 0,84	ca. 0,80	ca. 0,79	ca. 0,80	ca. 0,78

Hinweis: Die genauen Werte hängen von den Modellparametern und der Cross-Validation-Aufteilung ab. Logistische Regression erzielt hier typischerweise eine bessere Trennleistung als ein einfacher Baum.

Tree

Name
Tree

Parameters

- ☒ Induce binary tree
- ☒ Min. number of instances in leaves: 2
- ☒ Do not split subsets smaller than: 5
- ☒ Limit the maximal tree depth to: 10

Classification

- ☒ Stop when majority reaches [%]: 95

☒ Apply Automatically

Logistic Regression

Name
Logistic Regression

Regularization type: None

Strength: Weak Strong N/A

☐ Balance class distribution

☒ Apply Automatically

Test and Score

☒ Cross validation

Number of folds: 5

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.819	0.809	0.806	0.808	0.809	0.590
Logistic Regression	0.851	0.791	0.790	0.790	0.791	0.555

Compare models by: Area under ROC curve

Negligible diff.: 0.1

	Tree	Logistic Regression
Tree		0.068
Logistic Regression	0.932	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Station 5: Auswertung und Interpretation

Zahlen allein genügen nicht – wir wollen verstehen, wo das Modell gut ist, wo es scheitert und warum.

5a Confusion Matrix

Hands-on

1. Evaluate → Confusion Matrix auf den Canvas ziehen und mit Test and Score verbinden.
2. Im Dropdown oben Logistic Regression auswählen.
3. Die Matrix zeigt vier Felder: True Positive, True Negative, False Positive, False Negative.
4. Aktiviere 'Proportions of predicted class' für relative Anteile statt absolute Zahlen.
5. Klicke auf ein Feld – die zugehörigen Instanzen werden markiert und können an nachfolgende Widgets weitergegeben werden.

Widget-Info: Confusion Matrix

Stellt dar, wie häufig das Modell jede mögliche Vorhersage getroffen hat – aufgeschlüsselt nach tatsächlicher und vorhergesagter Klasse.

- True Positive (TP): Korrekt als 'überlebt' klassifiziert
- True Negative (TN): Korrekt als 'nicht überlebt' klassifiziert
- False Positive (FP): Fälschlich als 'überlebt' – Typ-I-Fehler
- False Negative (FN): Fälschlich als 'nicht überlebt' – Typ-II-Fehler

5b ROC-Analyse

Hands-on

1. Evaluate → ROC Analysis auf den Canvas ziehen und mit Test and Score verbinden.
2. Beide Modelle (Tree und Logistic Regression) werden gleichzeitig dargestellt.
3. Beobachte: Die Kurve der Logistic Regression liegt weiter oben-links – bessere Trennleistung.
4. Die gestrichelte Diagonale entspricht einem zufälligen Klassifikator ($AUC = 0,5$) – je weiter eine Kurve davon abweicht, desto besser das Modell.

Widget-Info: ROC Analysis

Zeigt den Kompromiss zwischen True Positive Rate (Sensitivität) und False Positive Rate für verschiedene Entscheidungsschwellen.

- $AUC = 1,0$: Perfekte Trennung der Klassen
- $AUC = 0,5$: Kein Vorteil gegenüber zufälligem Raten
- Besonders geeignet bei unbalancierten Klassen (hier: 62 % nicht überlebt, 38 % überlebt)

5c Baumvisualisierung

Hands-on

1. Model → Tree Viewer auf den Canvas ziehen.
2. Direkt das Tree-Widget (nicht Test and Score) mit Tree Viewer verbinden.
3. Der vollständige Entscheidungsbaum erscheint. Der erste Split erfolgt meist nach 'Sex'.
4. Mit dem Schieberegler 'Depth' die Tiefe einschränken – Tiefe 3 ist gut erklärbar und zeigt die wichtigsten Entscheidungswege.
5. Auf einen Knoten klicken: Die zugehörigen Instanzen werden hervorgehoben und können an Scatter Plot weitergegeben werden.

Widget-Info: Tree Viewer

Visualisiert den gelernten Entscheidungsbaum interaktiv. Jeder Knoten zeigt das Trennmerkmal, den Schwellwert sowie die Klassenverteilung der darin enthaltenen Instanzen.

- Tiefer Baum: Hohe Trainingsgenauigkeit, aber Overfitting-Gefahr
- Flacher Baum (Tiefe 3–4): Meist robuster und im Unterricht besser interpretierbar
- Verbinde Tree Viewer mit Scatter Plot: Gewählter Knoten → Punkt-Highlight im Merkmalsraum

4 Zusammenfassung

Wir haben alle Kernschritte einer ML-Pipeline mit Orange durchlaufen:

Station	Widgets	Ziel
1 – Laden	File	Rohdaten importieren, Spaltentypen prüfen
2 – EDA	Data Table, Distributions, Scatter Plot	Verteilungen und Muster verstehen
3 – Preprocessing	Select Columns, Impute	Uninformative Features entfernen, Lücken füllen
4 – Training	Tree, Logistic Regression, Test and Score	Modelle trainieren und objektiv vergleichen
5 – Auswertung	Confusion Matrix, ROC Analysis, Tree Viewer	Fehlerquellen verstehen, Modell interpretieren

Orange macht den ML-Prozess transparent: Jede Entscheidung ist sichtbar, jeder Schritt diskutierbar. Das macht es zu einem ausgezeichneten Werkzeug, um ML-Konzepte im Unterricht zu erschließen – sowohl für Lernende ohne Programmiererfahrung als auch als Einstieg in tiefergehende Python-Implementierungen.

Hinweis: Nächste Schritte

Eigene Datensätze: Orange lädt jede CSV-Datei – probiere z. B. den Pinguin- oder Apfeldatensatz.
Add-ons erkunden: Unter Options → Add-ons sind Text Mining, Time Series und Image Analytics verfügbar.

Python-Integration: Orange lässt sich als Python-Bibliothek einbinden – natürliche Brücke zur Programmierung.

Offizielle Dokumentation und Video-Tutorials: <https://orangedatamining.com/blog/>

Ressourcenkarte

Woher bekomme ich Daten für den Unterricht mit Orange?

1 Sofort startklar: Eingebaute Datensätze in Orange

Orange liefert über das Widget „Datasets“ zahlreiche fertige Datensätze mit. Für den Einstieg im Unterricht reichen diese völlig aus — kein Download, kein Import, kein Aufräumen.

Datensatz	Inhalt	Gut für	Unterrichtsbezug
Zoo	101 Tiere, 17 Merkmale	Klassifikation, Decision Tree	Biologie, Sachunterricht
Iris	150 Schwertlilien, 4 Merkmale	Klassifikation, Clustering	Biologie, Mathematik
Titanic	Überlebende der Titanic	Klassifikation, Ethik-Diskussion	Geschichte, Ethik, Gemeinschaftskunde
Heart Disease	Medizinische Patientendaten	Klassifikation, Datenschutz	Biologie, Ethik
Housing	Wohnungspreise Boston	Regression	Mathematik, Sozialkunde
Paint Data (Widget)	Selbst gemalte Punktwolken	Clustering, Klassifikation	Mathematik, Exploration

i Tipp für den Unterricht

Starten Sie immer mit einem eingebauten Datensatz. Die Schülerinnen und Schüler lernen so die Werkzeuge kennen, ohne sich gleichzeitig mit Datenqualität herumschlagen zu müssen.

2 Daten selbst erzeugen: Die Erhebung IST der Unterricht

Eigene Datenerhebung ist didaktisch besonders wertvoll: Die Schülerinnen und Schüler erleben den gesamten Weg von der Messung bis zur Vorhersage — und verstehen, warum Datenqualität entscheidend ist.

Idee	Erhobene Merkmale	ML-Aufgabe	Fach
Körperdaten der Klasse	Körpergröße, Schuhgröße, Handspanne, Armspanne (anonym)	Klassifikation (z.B. Geschlecht) oder Regression	Mathematik, Sport
Geometrische Objekte vermessen	Länge, Breite, Diagonale, Gewicht	Klassifikation (Formtyp vorhersagen)	Mathematik, Physik
Schulhof-Wetter-Station	Temperatur, Luftfeuchtigkeit, Windstärke, Bewölkung	Regression (Temperatur vorhersagen) oder Clustering	Geographie, Physik, NwT
Papierfliegerwettbewerb	Flügelspannweite, Papiergewicht, Faltungen, Flugweite	Regression (Flugweite vorhersagen)	Physik, Technik
Songmerkmale bewerten	Tempo, Lautstärke, Stimmung, Genre (subjektiv)	Clustering (Musik-Typen finden)	Musik, Deutsch

Idee	Erhobene Merkmale	ML-Aufgabe	Fach
Texte der Klasse	Aufsätze oder Kurzgeschichten als Textkorpus	Text Mining / Clustering	Deutsch, Fremdsprachen
Handyfotos von Objekten	z.B. Äpfel vs. Birnen, Blätter, Schuhe	Bildklassifikation (Image Analytics Add-on)	Biologie, Kunst, BNT

✓ Praxis-Tipp: So geht's in 5 Minuten

1. Spaltenüberschriften gemeinsam an der Tafel festlegen.
 2. Jede/r Schüler/in trägt eigene Zeile in ein geteiltes Tabellendokument ein.
 3. Als CSV exportieren → in Orange über „File“ laden → fertig.
- Ergebnis: 25–30 Datenpunkte in wenigen Minuten — genug für erste Modelle.

3 Offene Datenquellen nach Fach

Kuratierte Quellen für saubere, unterrichtstaugliche Datensätze — kein Kaggle-Dschungel.

Fachbereich	Quelle	Was gibt es dort?	Beispiel-Datensatz
Mathematik / Statistik	Gapminder (gapminder.org)	Länderdaten über Zeit: BIP, Lebenserwartung, Bevölkerung	Lebenserwartung vs. Einkommen (Regression)
Mathematik / Statistik	Statistisches Landesamt BW	Regionale Daten: Bevölkerung, Wahlen, Wirtschaft	Gemeindedaten clustern
Naturwissenschaften	UCI ML Repository	Klassische, saubere ML-Datensätze	Seeds, Wine, Glass (Klassifikation)
Naturwissenschaften	DWD Open Data (Deutscher Wetterdienst)	Historische Wetterdaten, frei verfügbar	Temperaturverlauf → Regression / Zeitreihen
Geographie / BNE	Our World in Data	Globale Daten: Klima, Energie, Gesundheit	CO ₂ -Emissionen nach Ländern (Clustering)
Geschichte / Ethik	Titanic (in Orange eingebaut)	Überlebenschancen nach Klasse, Geschlecht, Alter	Wer überlebt? → Ethik-Diskussion
Gesellschaftskunde	EU Open Data Portal	EU-weite Statistiken zu Bildung, Arbeit, Migration	Ländervergleiche → Clustering
Sport	Bundesliga-Daten / Olympia-Ergebnisse	Spielstatistiken, Ergebnisse, Athletendaten	Leistungsvorhersage (Regression)
Sprachen / Deutsch	Projekt Gutenberg-DE, Zeitungsartikel	Frei verfügbare Texte für Text Mining	Märchen nach Autor clustern (Text Mining Add-on)
Informatik / frei	Orange Datasets (eingebaut)	Über 30 fertige Datensätze in Orange	Zoo, Iris, Heart Disease, Housing

4 Das Stufenmodell: Schritt für Schritt zu eigenen Daten

Nicht alles auf einmal — dieser Dreischritt hat sich in der Praxis bewährt:

Stufe 1 Eingebaute Datensätze <i>Werkzeuge kennenlernen, Pipeline verstehen</i>	Stufe 2 Eigene Klassendaten <i>Datenerhebung als Teil des Unterrichts erleben</i>	Stufe 3 Offene Datenquellen <i>Gemeinsam mit SuS recherchieren und bewerten</i>
--	--	--

5 Checkliste: Ist mein Datensatz unterrichtstauglich?

Kriterium	Frage	Warum wichtig?
Verständlichkeit	Verstehen die SuS, was in den Spalten steht?	Ohne Verständnis der Merkmale kein Lerneffekt
Größe	Mindestens 50, besser 100+ Datenpunkte?	Zu wenige Daten → Modell lernt nichts Sinnvolles

Kriterium	Frage	Warum wichtig?
Vollständigkeit	Wenige fehlende Werte? Keine kryptischen Codes?	Datenbereinigung frisst sonst die gesamte Stunde
Format	Liegt als CSV oder Excel vor?	Orange importiert CSV und XLSX direkt
Datenschutz	Keine personenbezogenen Daten ohne Einwilligung?	DSGVO gilt auch im Klassenzimmer
Relevanz	Hat der Datensatz Bezug zum Fach oder Alltag der SuS?	Motivation und Transfer steigen mit Lebensweltbezug

i Die eigentliche Kompetenz

Das Problem im Unterricht ist nicht Datenmangel — sondern Datenüberfluss.

Die Kernfrage, die Schülerinnen und Schüler lernen sollen: Welche Daten taugen für welche Frage? Was steht in den Spalten? Was fehlt? Wo lauern Verzerrungen?