

Aufgabe 1:

Sie sind Auszubildende/r im zweiten Jahr bei der OnlineWelt GmbH, einem Versandhaus für Alltagswaren. Ihr Unternehmen möchte zukünftig ein KI-Modell einsetzen, um die Kunden besser zu verstehen und die Kundenansprache zu personalisieren. Bisher sammelt das Unternehmen Daten über Kundeninteraktionen auf der Website, Feedback nach dem Kauf und die Kaufhistorie. Diese Daten sollen als Trainingsdaten für das KI-Modell dienen.

1a) Welche Ziele könnte die OnlineWelt GmbH mit einem KI-Modell verfolgen, bzw. welchem Zweck könnte ein KI-Modell dienen? Nennen Sie zwei Beispiele.

1b) Welche Algorithmen könnten für das Erstellen eines KI-Modells eingesetzt werden? Nennen Sie drei Beispiele von Algorithmen aus dem Bereich der Künstlichen Intelligenz und definieren Sie in Stichworten deren Einsatzbereiche.

1c) Zeigen Sie anhand eines selbstgewählten Beispiels auf, wie es bei der KI-gestützten Kundenanalyse zu einem algorithmischen Bias kommen kann.

1d) Schlagen Sie der Marketingabteilung begründete Empfehlungen zur Gewährleistung der Datensicherheit vor.

Aufgabe 2:

Im Datenbank-System der OnlineWelt GmbH gibt es unter anderem Datenbank-Einträge, mit denen Uhrzeiten erfasst werden, zu denen die Nutzer eingekauft haben. Zukünftig möchte die OnlineWelt GmbH auch die Software für die Auswertung der gesammelten Uhrzeiten der letzten Jahre liefern. Die Forschungs- und Entwicklungsabteilung soll deshalb ein KI-Modell entwickeln, das die häufigsten Uhrzeiten von Onlinekäufen vorhersagen kann.

2a) Herr Mustermann, ein Mitarbeiter aus der Forschungs- und Entwicklungsabteilung, möchte versuchen, diese Aufgabe mit einem Entscheidungsbaum (decision tree) zu lösen. Er plant, 20 % der Daten für das Training, 30% der Daten für die Validierung und 50 % der Daten zum Testen des Algorithmus zu nutzen. Erläutern sie zunächst den Unterschied von Trainings- Validierungs und Testdaten

2b) Beurteilen Sie die geplante Aufteilung der vorhandenen Datensätze.

2c) Herr Mustermann wendet seinen Entscheidungsbaum am Testdatensatz an und trägt die Ergebnisse in die untenstehende Tabelle (Anlage 3) ein. Er möchte jetzt herausfinden wie hoch die Accuracy ist, die über $(TP+TN)/(TP+TN+FP+FN)$ definiert ist. Ordnen Sie den Daten in der Tabelle die jeweils passende Abkürzung aus der Formel zu.


		Tatsächlich Mittags	Tatsächlich Abends
Klassifizierung durch den Entscheidungsbaum	Mittags	45	15
	Abends	15	25

2d) Berechnen Sie die Accuracy anhand dieser Daten.

Aufgabe 3:

Die Marketingabteilung möchte die erfassten Daten für weitere Analysen einsetzen. Es soll vorhergesagt werden, ob ein Kunde mehr online kauft, wenn er zufriedener ist. Die gesammelten Daten werden Ihnen als Punktediagramm vorgelegt. Abgebildet wurde die Anzahl monatlicher Käufe der Kunden aufgetragen gegen die gemessene Zufriedenheit.

3a) Zeichnen Sie eine mögliche Regressionsgerade in das Diagramm (Anlage 4) ein.



3b) Schätzen sie grob den Korrelationskoeffizienten ab: Ist er positiv oder negativ? Begründen Sie kurz Ihre Einschätzung.


3c) Tatsächlich fehlen in den bisherigen Daten die Werte für eine Zufriedenheitswert von 9. Bestimmen Sie grafisch, wie viele Käufe vermutlich bei einem solch zufriedenen Kunden zu erwarten wären.

3d) Stellen Sie die Funktionsgleichung zu der von Ihnen eingezeichneten Regressionsgeraden auf.


3e) Gegeben ist die folgende Werteverteilung:

7	4	5	8	11	16	12	18	9	10
---	---	---	---	----	----	----	----	---	----


Welche der drei Boxplots stellt diese Wertetabelle korrekt dar? Begründen Sie ihre Antwort.



A



B



C