

Zielgruppe A: 10-12 Jahre (Mittelstufe)

Thema: Wie lernt ein Computer, Fruechte zu unterscheiden?

1. Datenerhebung

Sammle insgesamt **15 Datenpunkte** (je 5 Erdbeeren, 5 Cocktailtomaten und 5 normale Tomaten). Arbeite im Modus **Gewicht (g) & Vitamin C (mg)**. Ziehe dazu die Fruechte aus den Koerben in das Messfenster.

Beobachtungsaufgabe:

Vergleiche die Messwerte in der Tabelle. Was faellt dir auf, wenn du eine Erdbeere mit einer Cocktailtomate und einer normalen Tomate vergleichst? Welche Frucht ist am schwersten? Welche hat am meisten Vitamin C?

Deine Beobachtung:

2. Modellbildung

Klicke auf **Modell trainieren**. Schau dir den Entscheidungsbaum in Bereich 5 an.

Aufgabe:

Notiere den Grenzwert, den die KI fuer das Gewicht festgelegt hat. Bei welchem Gewicht unterscheidet die KI zwischen den Fruchtarten?

Grenzwert Gewicht: _____ g

Verstaendnisfrage:

Warum hat die KI genau diesen Wert gewaehlt und nicht z.B. 5g oder 150g?

Deine Erklaerung:

3. Ueberpruefung (Testlauf)

Gib im Testlauf (unten in der App) Werte ein, die *zwischen* typischen Werten liegen - z.B. Gewicht 40g und Vitamin C 15mg.

Diskussionsfrage:

Hat die KI mit ihrer Vorhersage recht? Kann eine KI auch Fehler machen, wenn die Daten nicht eindeutig sind? Was koennte passieren, wenn es eine Frucht gibt, die genauso schwer ist wie eine Cocktailtomate, aber so viel Vitamin C hat wie eine Erdbeere?

Deine Antwort:

Zielgruppe B: 15-18 Jahre (Oberstufe)

Thema: Klassifikationsalgorithmen und Feature-Engineering

1. Analyse der Trennschaerfe

Fuehre Messreihen mit mindestens **18 Datenpunkten** (je 6 pro Klasse) in **allen drei Modi** durch:

- Modus A: Gewicht (g) & Vitamin C (mg)
- Modus B: Zuckergehalt (%) & Gewicht (g)
- Modus C: Vitamin C (mg) & Zuckergehalt (%)

Hypothese:

Welches Feature-Paar erlaubt die praeziseste Trennung der drei Klassen? Begruende deine Wahl anhand der Ueberlappungen im Diagramm und der Struktur des Entscheidungsbaums.

Bestes Feature-Paar: _____ Begrueendung:

2. Funktionsweise des CART-Algorithmus

Das Programm verwendet den **CART-Algorithmus (Classification and Regression Trees)** mit dem **Gini-Index** als Unreinheitsmass zur Bestimmung der optimalen Splits.

Analyse:

Betrachte die gestrichelten Linien im Diagramm. Fuege gezielt Ausreisser hinzu (z.B. sehr grosse Erdbeeren oder sehr kleine Tomaten) und trainiere das Modell neu. Wie veraendern sich die Decision Boundaries? Dokumentiere deine Beobachtungen.

Beobachtung bei Ausreissern:

3. Evaluation & Transfer

Kritische Reflexion:

Der vorliegende Baum hat eine maximale Tiefe von 2 (ein Hauptsplit und ein weiterer Split auf einer Seite). Erklare, warum ein tieferer Baum (mehr Verzweigungen) bei diesem Datensatz zu Overfitting fuehren koennte.

Erklaerung Overfitting:

Praktische Aufgabe:

Exportiere deine Daten als CSV. Berechne manuell den Mittelwert des Gewichts fuer jede der drei Klassen. Vergleiche den tatsaechlichen Split-Wert des Modells mit dem Mittelwert zwischen den Klassen.

Durchschnitt Erdbeere	Durchschnitt C.-Tomate	Durchschnitt N. Tomato
_____ g	_____ g	_____ g

Lehrer-Infoblatt: Die Mathematik hinter dem KI-Labor

1. Der Algorithmus: CART mit Gini-Index

Die App verwendet einen echten **CART-Algorithmus (Classification and Regression Trees)** mit dem **Gini-Index** als Unreinheitsmass. Der Gini-Index fuer eine Gruppe berechnet sich als:

$$Gini = 1 - \sum (p_i^2)$$

wobei p_i der Anteil der Klasse i in der Gruppe ist. Der Algorithmus sucht den Split, der den gewichteten Gini-Index minimiert.

2. Die drei Klassen und ihre Wertebereiche

Klasse	Gewicht (g)	Vitamin C (mg)	Zucker (%)
Erdbeere	11 - 14	7,5 - 9,5	4 - 6
Cocktailtomate	15 - 25	4 - 4,5	3,5 - 5
Normale Tomate	65 - 100	26 - 34	2 - 4

3. Die Visualisierung im 2D-Raum

Da zwei Merkmale gemessen werden, arbeitet die KI in einem **zweidimensionalen Merkmalsraum**. Jedes Objekt ist ein Vektor $v = (f_1, f_2)$.

- Split 1 teilt den Raum vertikal oder horizontal (je nach besserem Gini-Wert).
- Split 2 unterteilt die unreinere Seite weiter.

Dadurch entstehen rechteckige Regionen, die im Scatterplot farbig hinterlegt sind. Dies demonstriert das Konzept der achsenparallelen linearen Trennbarkeit, die typisch fuer Entscheidungsbaeume ist.

4. Didaktische Hinweise

Sensitivitaet gegenueber Ausreissern:

Da der Gini-Index auf Klassenverteilungen basiert, reagiert das Modell empfindlich auf Ausreisser. Ein einzelner falsch gelabelter Datenpunkt kann die Trennlinie erheblich verschieben.

Generalisierung vs. Overfitting:

Schueler koennen beobachten, dass ein Modell alle Trainingspunkte korrekt klassifiziert (100% Training-Accuracy), aber beim Testlauf versagt, wenn die Testdaten untypisch sind.

Feature-Engineering:

Die drei Modi zeigen, dass die Wahl der richtigen Features (Merkmale) entscheidend fuer die Modellqualitaet ist. Im Modus A (Gewicht & Vitamin C) sind alle drei Klassen gut trennbar. Im Modus B ueberlappen Erdbeeren und Cocktailtomaten beim Zuckergehalt teilweise.

5. Technische Hinweise zur App

- Die Baumtiefe ist auf maximal 2 begrenzt (fuer didaktische Klarheit).
- Mindestens 5 Datenpunkte sind erforderlich, um das Modell zu trainieren.
- Die Fruechte in den Koerben sind nicht individuell unterscheidbar - jeder Drag erzeugt einen randomisierten Datenpunkt innerhalb der klassenspezifischen Wertebereiche.
- CSV-Export ermoeeglicht die Weiterverarbeitung in Excel oder Python.